

Sistematização - Ciência de Dados II

Docente: Romes Heriberto Pires de Araujo
Discente: Thamires Gil Godoy

Setembro de 2026

1. PROBLEMA E DATASET

Para a sistematização escolheu-se abordar o universo do streaming Spotify, mais especificamente com seus produtos de podcasts e entender se existem condições que possam influenciar positivamente um determinado programa estar entre os 200 mais ouvidos do mundo.

O conjunto de dados escolhido foi extraído do Kaggle (link: <https://www.kaggle.com/datasets/daniilmiheev/top-spotify-podcasts-daily-updated/data>) e contém os seguintes atributos coletados do dia 01/09/2024 a 26/07/2026 na plataforma de streaming.

Tabela 1 - Conjunto de dados.

Dados	Descrição
date	data em que o episódio foi ranqueado
rank	posição em que o episódio foi ranqueado
region	região em país do episódio
chartRankMove	variação na classificação com relação ao dia anterior
episodeUri	identificador do episódio
showUri	identificador do programa
episodeName	nome do episódio
description	descrição do episódio
show.name	nome do programa
show.publisher	editora da produção
duration_ms	duração do episódio em milissegundos
explicit	informa se o conteúdo do episódio é explícito ou não
languages	idioma em que o episódio foi feito
release_date	data de lançamento do episódio
show.media_type	forma de mídia do episódio (áudio, vídeo)
show.total_episodes	episódios totais do programa

A execução realizou-se no Google Collaboratory.

2. PRÉ-PROCESSAMENTO

1.1 Ingestão dos dados

Para o consumo dos dados, inicialmente se instalou o Kaggle e se importou as bibliotecas e funções necessárias. Em seguida, os dados foram baixados e lidos usando o Spark. A princípio, a leitura dos dados era feita mostrando os quinze primeiros registros e essa pequena amostragem não permitiu identificar, inicialmente, o embaralhamento dos registros. Isso é, observou-se que havia registros em que o dado referente a uma coluna estava em outra; mas isso foi corrigido.

1.2 Limpeza dos dados

O primeiro passo para a limpeza consistiu em renomear as colunas para a melhorar compreensão e para evitar que caracteres especiais ocasionaram futuros erros, essa renomeação pode ser conferida na Tabela 2. Depois, excluiu-se duas colunas que não iriam ser processadas: id_episodio e id_programa.

Tabela 2 - Renomeação das colunas do conjunto de dados.

Nome anterior	Renomeação
date	data
rank	posicao
region	pais
chartRankMove	var_classifica
episodeUri	id_episodio
showUri	id_programa
episodeName	nome_episodio
description	descricao
show.name	nome_programa
show.publisher	editora
duration_ms	duracao_ms
explicit	explicito

languages	idioma
release_date	data_lancamento
show.media_type	forma_midia
show.total_episodes	epis_totais

Buscando a relevância de nulos no conjunto de dados, calculou-se a porcentagem de nulos para cada coluna e o maior valor obtido foi de 0,00873% para a coluna descricao. Isso indica um conjunto de dados robusto e com poucas lacunas. Essa análise também permitiu observar que a porcentagem de dados nulos em posicao, pais, var_classifica e nome_episodio é a mesma; então, questionou-se se o registro que é nulo em uma dessas colunas também é nulo nas outras.

Ao se contar a quantidade de registros nulos ao mesmo tempo nessas quatro colunas descobriu-se que sempre que uma dessas colunas estava sem dados, as outras três também estavam. Indica-se que independente dessa análise, o procedimento aos nulos dessas colunas seria o mesmo: exclusão.

O tratamento dos demais valores nulos seguiu da seguinte forma:

- descricao: preencher com "nao informado"
- nome_programa: preencher com "nao informado"
- editora: preencher com "nao informado"
- duracao_ms: colocar a media dos outros registros do mesmo programa
- explicito: excluir registros nulos
- idioma: copiar de outro registro do mesmo programa (quando disponível)
- data_lancamento: excluir registros nulos
- forma_midia: excluir registros nulos
- epis_totais: copiar de outro registro do mesmo programa (quando disponível)

Aos dados a serem preenchidos com “nao informado” e aos dados a serem excluídos, a execução em seguida se realizou; mas para os demais, o tratamento de valores nulos pausou. Essa pausa se deu momentaneamente para corrigir os dados embaralhados.

A estratégia partiu da examinação das colunas: país, nome_programa e idioma. A seleção de valores únicos da coluna país não retornou nenhum dado condizente, e todos os códigos dos países estavam de acordo com a ISO. Seguindo para a coluna idioma, o resultado não foi o esperado e diferentes tipos de dados foram exibidos, como mostra a Figura 1.

Figura 1 - Exibição dos dados de idioma não limpos.

```
+-----+
|idioma
+-----+
| die du mit Krömer teilen möchtest? Schicke uns gerne eine E-Mail an feelings@wonderly.com.+++ A
| known for their practicality and relevance even in today's modern world
| what they are doing now to Jill Stein and what they did to Tulsi Gabbard
|All-In Podcast, LLC
| mais aussi d'avoir un autre point de vue sur des comportements qui ne sont pas si anormaux que
| korzystając z rachunku rzeczywistego w OANDA TMS Brokers. Zapoznaj się z warunkami promocji na
| der Sicherheitsexperte bei der Bertelsmann-Stiftung und dort Direktor des Programms ""Europas
| self-care
| entre em contato conosco pelo e-mail: contato@petitjournal.com.br"
| un ragazzone un po' dimenticone che con la sua negligenza si è trasformato da semplice nerd
|401893.0
|Przemek Górczyk Podcast
|Zbrodnie Bez Cenzury
```

Tendo o conhecimento que os dados de idiomas estavam entre colchetes, utilizou-se desse princípio para excluir todos os registros cujo idioma não estava limitado por []. E ao pedir para imprimir os 200 primeiros registros, de forma única, todos os 76 idiomas apareceram e os dados estavam condizentes.

Seguindo para os dados de nome_programa, os 1000 primeiros registros foram mostrados de forma única e o que se observou foram 600 dados aparentando ser nomes de programas. Esse julgamento considerou que os títulos costumam ser curtos e utilizar letras maiúsculas intercalando com minúsculas.

Ao chegar nesse ponto se contabilizou a perda de registros no conjunto de dados:

- Quantidade de linhas antes da limpeza: 1377223
- Quantidade de linhas depois da limpeza: 1238021
- Porcentagem de linhas removidas: 10,11 %

A contabilização de nulos por colunas foi feita e apenas epis_totais ainda constava com esse tipo de dado. Assim, não houve a necessidade de colocar o valor médio no caso de duracao_ms, ou copiar o dado de outro registro considerando o mesmo programa para o idioma.

Para finalizar o tratamento de nulos, o último passo, foi copiar o dado de epis_totais de outro registro, considerando o mesmo programa, para aquele dado

que estava nulo. E dos 964 registros, 963 foram preenchidos dessa forma, sendo o único restante, excluído. Esse único registro excluído permaneceu nulo pois não encontrou um nome de programa correspondente para poder copiar o dado de epis_totais. Assim, a quantidade de linhas passou de 1377223, para 1238020.

Durante a execução da limpeza, observou-se também que os tipos de dados estavam todos como string, assim, o procedimento seguinte foi fazer as transformações:

- data: string --> date
- duracao_ms: string --> float
- explicito: string --> booleano
- data_lancamento: string --> date
- epis_totais: string --> float --> int (evitando a ocorrência de NULL)

Para enriquecer a análise criou-se uma nova coluna chamada faixa_duracao, classificando cada episódio em três categorias: episódios com menos de 15 minutos, classificados como curto, episódios entre 15 e 45 minutos como médio e episódios acima de 45 minutos, longo.

Criou-se também outra coluna derivada, com o objetivo de facilitar a análise temporal. A mes_ano extrai apenas o mês e o ano da data original do registro, sem a informação de dia, facilitando uma futura análise gráfica.

3. ANÁLISE EXPLORATÓRIA


Após o pré-processamento, algumas perguntas de negócios puderam ser realizadas e respondidas utilizando o Spark SQL.

- 1. Qual a nacionalidade do primeiro colocado a cada mês? E com que frequência esse país aparece?*
- 2. Qual país tem mais conteúdo explícito?*
- 3. Considerando o país com mais conteúdo explícito, quantos episódios foram explícitos e quantos não foram?*
- 4. No Brasil, quantos episódios são de longa, média e curta duração?*
- 5. Quais são os 10 idiomas predominantes na lista, considerando a quantidade de episódios em cada idioma?*

A primeira questão objetiva trazer um panorama da predominância cultural e geográfica dentro do conjunto Assim é possível observar se determinados países se concentram mais vezes no topo ou se há uma diversidade entre eles.

O resultado, demonstrado graficamente, conforme Figura 2, mostra que se um podcast é colombiano, ele tem mais chance de ser o mais ouvido do mundo em determinado mês. Observa-se ainda que, à exceção das Filipinas e da Indonésia, os demais países que aparecem são hispano-falantes, sugerindo que produções oriundas de países hispânicos possuem maior propensão de alcançar o topo.

Figura 2 - Ocorrência de países na primeira colocação entre os episódios.



A segunda questão busca identificar qual país concentra maior quantidade de conteúdo explícito entre os duzentos podcasts mais ouvidos, e a terceira aprofunda essa análise ao investigar a proporção desse tipo de conteúdo dentro desse.

O resultado, apresentado em formato de cartão (Figura 3), mostrou que o Reino Unido é o país que, dentre os duzentos podcasts mais populares no período analisado, possui maior incidência de produções classificadas como explícitas. Isso

pode sugerir uma característica cultural, onde pessoas desse país são mais tolerantes a determinados conteúdos e assuntos.

Figura 3 - País que mais consome episódios explícitos.

**País com mais conteúdo explícito:
Reino Unido**


Mas considerando que esse país é o de maior aceitação a determinados tipos de conteúdo, verifica-se que episódios com conteúdos explícitos estão longe de ser a maioria. Ou seja, um conteúdo que não abarque linguagem imprópria, temas adultos, violência ou discussões sobre sexualidade tem maior propensão a estar entre os duzentos mais ouvidos do mundo.

Em seguida, na Figura 4, é observado o gráfico dicotômico mostrando a proporção de episódios explícitos e não explícitos no Reino Unido.

Figura 4 - Proporção de episódios explícitos e não explícitos no Reino Unido.

EXPLICITO X NÃO EXPLICITO

Análise do país com maior número absoluto de episódios explicitos entre os TOP 200




A pergunta 4 é mais regional, e questiona se os episódios mais ouvidos no Brasil são de média, curta ou longa duração. O resultado, melhor visto no gráfico da

Figura 5, mostra que dos 100% dos episódios brasileiros nos duzentos mais ouvidos, a maioria, 47%, é de longa duração, ou seja, com mais de 45 minutos.

Esse achado sugere que, no contexto brasileiro, há uma preferência por conteúdos mais extensos. Assim, de forma preliminar, infere-se que programas brasileiros que almejam alcançar os mais ouvidos do mundo poderiam se beneficiar ao investir em episódios mais longos, contudo, essa é uma interpretação inicial.

Figura 5 - Faixa de duração dos episódios brasileiros mais ouvidos.




A última questão busca identificar os dez idiomas predominantes na lista, considerando a quantidade de episódios disponíveis em cada um deles. O objetivo dessa análise é compreender a distribuição linguística dentro do conjunto de dados, destacando quais idiomas possuem maior representatividade entre os conteúdos mais ouvidos.

O resultado apresentado é o esperado, o inglês é o idioma mais popular entre os episódios listados, seguido do espanhol. Interessante notar que, apesar do mandarim e hindi serem idiomas extremamente falados no mundo, eles não

aparecem nesse ranking. Isso, provavelmente, indica uma barreira do streaming em acessar essas populações, seja por questões políticas ou culturais.

Figura 6 - Quantidade de episódios dentre os dez idiomas mais populares.



4. MODELAGEM PREDITIVA

Nessa etapa, se objetivou a criação de dois modelos preditivos e a comparação entre eles. Com o intuito de se estimar a posição diária de um episódio entre os 200 primeiros, um modelo de Regressão Logística (RL) e outro de Random Forest (RF) foram elaborados.

A RL é um modelo estatístico que permite interpretar a relação entre variáveis independentes e a probabilidade de ocorrência de determinada classe. A RF, por sua vez, é um conjunto de árvores de decisão, apresentando mais robustez

e capacidade de generalização em cenários com variáveis heterogêneas. Antemão a aplicação dos dois modelos, as variáveis foram compreendidas e preparadas; a Tabela 3 explica melhor essa relação.

Tabela 3 - Variáveis usadas nos modelos.

Variável	Tipo	Descrição
posicao	independente categórica ordinal	posição do episódio no ranking
pais	dependente categórica nominal	país de origem do episódio
nome_programa	dependente categórica nominal	nome do programa referente ao episódio
idioma	dependente categórica nominal	idioma em que o episódio foi publicado
faixa_duracao	dependente categórica ordinal	duração do episódio em curto, médio e longo
dif_tempo	dependente numérica discreta	contagem de dias entre o lançamento do episódio e quando ele apareceu no ranking

Com relação ao tipo, para que o modelo possa se utilizar da estatística, os dados categóricos foram indexados, isso é, cada categoria textual foi convertida em valores numéricos.

Treinou-se os modelos com 60% dos dados, e os 40% restantes foram usados para teste. Escolheu-se essa distribuição devido ao custo computacional, onde ao se utilizar uma proporção de 80% para treino e 20% para teste os resultados não tiveram melhora e demoravam mais para execução.

4.1 Modelos de Treinamento

A RL é um modelo estatístico clássico utilizado para problemas de classificação. Ele se baseia em estimar a probabilidade de um determinado evento ocorrer a partir de variáveis explicativas, aplicando a função logística para transformar valores contínuos em probabilidades entre 0 e 1. É bastante utilizada quando se deseja interpretar a relação entre os atributos e o resultado, já que

fornece coeficientes que indicam a direção e a intensidade da influência de cada variável sobre a classe prevista.

O modelo RF, por outro lado, é um algoritmo de aprendizado de máquina baseado em conjuntos de árvores de decisão. Ele constrói diversas árvores independentes durante o treinamento e combina seus resultados para gerar uma previsão final mais robusta. Essa abordagem reduz o risco de sobreajuste e melhora a capacidade de generalização do modelo, sendo especialmente útil em cenários com variáveis heterogêneas e relações complexas. Ou seja, enquanto a RL privilegia a interpretação estatística, a RF busca o melhor desempenho preditivo por meio da agregação de múltiplos classificadores.

4.2 Avaliação dos modelos

Os resultados obtidos evidenciam que tanto a RL quanto a RF tiveram um desempenho limitado ao tentar prever a variável alvo, ou seja, a posição do episódio. A RL alcançou uma acurácia de apenas 0,0174, com valores igualmente baixos para F1, precisão e recall, o que indica que o modelo praticamente não conseguiu distinguir corretamente as classes.

De forma não tão diferente, a RF teve um desempenho inferior, com acurácia de 0,0118 e métricas igualmente próximas de zero, revelando que suas previsões foram pouco melhores do que escolhas aleatórias. Para tentar melhorar os modelos preditivos, outras classes foram incluídas, ao todo sete variáveis independentes; e também aplicou-se a validação cruzada. No entanto, o resultado das quatro métricas, para os dois modelos, não ultrapassaram nem 0,2.

Como melhorar a robustez do modelo não influenciou em melhores resultados, optou-se pelo menor custo computacional. A Tabela 4 mostra o resultado das métricas para os dois modelos, onde utilizou-se as variáveis da Tabela 3 e a divisão de 60/40 para treinamento e teste. Ao analisar esses resultados, por mais baixo que sejam, percebe-se o contrário do esperado, a RL teve valores um pouco superiores.

Tabela 4 - Resultado das métricas avaliativas.

Métrica	Regressão Logística	Random Forest
Acurácia	0,0174	0,0118

F1	0,0127	0,0047
Precisão	0,0123	0,0090
Recall	0,0174	0,0118

Esses números sugerem que os atributos utilizados não oferecem informações suficientes para explicar a variação da posição diária dos episódios, ou que o problema em si é de alta complexidade, dependendo de fatores externos não capturados nos dados. Em síntese, os resultados mostram que, com as variáveis disponíveis, os algoritmos testados não fornecem estimativas confiáveis, apontando para a necessidade de repensar tanto a formulação do problema quanto a seleção e construção de variáveis mais informativas.

5. MODELAGEM DESCRITIVA

A modelagem descritiva tem como finalidade compreender padrões e relações entre variáveis, permitindo identificar tendências e levantar hipóteses sobre o comportamento observado. Neste trabalho, mesmo após a modelagem preditiva não ter apresentado resultados satisfatórios com as variáveis selecionadas, optou-se por mantê-las para fins didáticos.

A primeira transformação realizada foi a criação da variável `dif_tempo`, que corresponde à diferença em dias entre a data de coleta do episódio e sua data de lançamento. Depois, foi necessário preparar as variáveis categóricas para utilização como entradas numéricas, assim, aplicou-se o `StringIndexer` para converter categorias em índices. Foram indexadas as variáveis de país, nome do programa, idioma, faixa de duração e posição no ranking.

Após a indexação, todas as variáveis foram reunidas em um único vetor de características por meio do `VectorAssembler`.


Do ponto de vista interpretativo, cada variável desempenha um papel específico: a diferença temporal avalia o tempo levado para um episódio alcançar o ranking após seu lançamento; índices país e idioma comparam padrões de consumo entre diferentes regiões; programa e faixa de duração ajudam a identificar

se determinados formatos têm maior chance de alcançar o ranking e a posição facilita análises estatísticas sobre a distribuição dos rankings.

Organizado os dados, o próximo passo consistiu em aplicar o K-Means, mas antes, pelo método do cotovelo descobriu-se um valor ideal para a quantidade de agrupamentos. O método, que determina o valor adequado de k , consiste em calcular o erro intra-agrupamento (WSSSE) para alguns valores de k e observar o comportamento da curva resultante.

Como teste, o k variou de 2 a 10 e um gráfico foi plotado como resultado, onde o eixo x representa o número de agrupamentos e o eixo y o erro intra-agrupamentos. A interpretação do gráfico segue a lógica de identificar o ponto em que a redução do erro deixa de ser significativa com o aumento de k , ou seja, o cotovelo da curva. E como resultado, o ponto de inflexão obteve um k de 6, conforme mostra a Figura 7.

Figura 7 - Gráfico resultante do método do cotovelo.



Em seguida, o k-means foi ajustado e a coluna de predição denominada cluster foi incluída, essa coluna indica a qual agrupamento cada episódio foi atribuído.

A visualização inicial dos resultados mostrou que episódios de um mesmo programa, como “Amiga Date Cuenta”, foram consistentemente alocados em um mesmo agrupamento. Isso sugere que o algoritmo conseguiu identificar padrões de similaridade, como idioma, país e faixa de duração. Além disso, realizou-se uma análise descritiva dos agrupamentos, como mostra a Figura 8.

Figura 8 - Análise descritiva dos agrupamentos.

cluster	total_registros	num_paises	num_idiomas	num_programas	media_dif_tempo
1	41444	22	26	144	1822.1943103947494
3	303349	22	43	1049	21.25136394054373
5	31164	22	68	4862	75.3180913874984
4	606234	22	42	683	16.878830616560602
2	85106	22	50	2196	68.62520856343853
0	170723	22	45	1488	56.76666295695366

O agrupamento 1, com cerca de 41 mil registros, apresentou uma média de diferença temporal extremamente elevada (mais de 1800 dias), indicando episódios antigos que continuam presentes nos rankings.

Os agrupamentos 3 e 4, que juntos concentram mais de 900 mil registros, apresentaram médias de diferença temporal muito baixas (entre 16 e 21 dias), caracterizando episódios recém-lançados que rapidamente entram nos rankings.

Os agrupamentos 0, 2 e 5 representam episódios de médio prazo, com diferenças temporais variando entre 56 e 75 dias. Esses grupos apresentam maior diversidade de idiomas e programas, sugerindo que, após o pico inicial de audiência, há uma sustentação moderada do consumo, distribuída entre diferentes mercados e formatos. Em especial, o 5 se destacou pela alta diversidade de idiomas e programas, indicando dispersão e variedade de conteúdos que conseguem manter relevância por algumas semanas.

Essa análise pode indicar, para um gestor, uma ação de marketing distinta; onde campanhas de marketing específicas para os agrupamentos de lançamentos (3 e 4) visaria a maior visibilidade nos primeiros dias. E para os episódios de catálogo, mais antigos (agrupamento 1), seria possível explorar estratégias de monetização e reforçar a importância de manter conteúdos antigos acessíveis.

CONCLUSÃO

A sistematização percorreu as etapas do ciclo KDD (Knowledge Discovery in Databases), desde a preparação dos dados até a extração de informações. Inicialmente, foi realizada a limpeza e transformação dos dados para garantir a consistência dos dados. Em seguida, aplicou-se técnicas de análise exploratória para compreender a distribuição das variáveis e responder alguns questionamentos de negócio.

Na sequência, foi conduzida a modelagem preditiva com o objetivo de se prever a posição no ranking de um episódio, mas, embora não tenha apresentado bons resultados com as variáveis escolhidas, serviu para identificar uma necessidade de melhoria do modelo. Para a modelagem descritiva, decidiu-se utilizar as mesmas variáveis da modelagem preditiva, se aplicando o k-means com seis agrupamentos, com isso, o conhecimento descoberto indicou que os episódios podem se agrupar por diferença de dias entre seu lançamento e sua coleta no ranking.

O estudo apresentou limitações, seja na modelagem preditiva, que teve uma baixíssima acurácia, ou na descritiva, que agrupou os dados em conjuntos pouco distintos. Portanto, seria recomendável ampliar o conjunto de variáveis, como dados de comportamento de usuários e métricas de engajamento, além de testar outras técnicas de clusterização e métodos de validação.

Em síntese, apesar das limitações, a sistematização cumpriu seu papel didático ao demonstrar o ciclo completo do KDD, desde a preparação dos dados até a extração de conhecimento aplicável.